

Presentazione Esame Architetture Dati

Dataset Degradation

Simone Rancati 900052
Michele Piovanelli 894433
Lorenzo Pina 894396


Obiettivo

Questo progetto punta a:

1. Analizzare il Dataset per la diagnosi del carcinoma mammario Wisconsin Breast Cancer Dataset;
2. Introdurre del Data Poisoning all'interno del Dataset;
3. Addestrare 3 modelli differenti con vari livelli di corruzione del Dataset;
4. Osservare come i modelli si comportano al variare della corruzione.

Informazioni sul dataset

Wisconsin Breast Cancer Dataset, di dimensione ridotta, presenta features derivate da osservazioni di masse tumorali, con la rispettiva diagnosi associata.



```
RangeIndex: 569 entries, 0 to 568
Data columns (total 32 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id                                     569 non-null    int64
1   diagnosis                             569 non-null    object
2   radius_mean                           569 non-null    float64
3   texture_mean                           569 non-null    float64
4   perimeter_mean                         569 non-null    float64
5   area_mean                             569 non-null    float64
6   smoothness_mean                       569 non-null    float64
7   compactness_mean                      569 non-null    float64
8   concavity_mean                        569 non-null    float64
9   concave points_mean                   569 non-null    float64
10  symmetry_mean                         569 non-null    float64
11  fractal_dimension_mean                569 non-null    float64
12  radius_se                             569 non-null    float64
13  texture_se                             569 non-null    float64
14  perimeter_se                           569 non-null    float64
15  area_se                               569 non-null    float64
16  smoothness_se                         569 non-null    float64
17  compactness_se                        569 non-null    float64
18  concavity_se                          569 non-null    float64
19  concave points_se                     569 non-null    float64
20  symmetry_se                           569 non-null    float64
21  fractal_dimension_se                  569 non-null    float64
22  radius_worst                          569 non-null    float64
23  texture_worst                         569 non-null    float64
24  perimeter_worst                       569 non-null    float64
25  area_worst                            569 non-null    float64
26  smoothness_worst                     569 non-null    float64
27  compactness_worst                     569 non-null    float64
28  concavity_worst                       569 non-null    float64
29  concave points_worst                  569 non-null    float64
30  symmetry_worst                        569 non-null    float64
31  fractal_dimension_worst                569 non-null    float64
dtypes: float64(30), int64(1), object(1)
```

Data engineering

La colonna "id" è stata rimossa data l'unicità dei valori, "diagnosis" è stata trasformata in numerica (1 = maligno, 0 = benigno) e la standardizzazione è stata effettuata post-corrruzione.

```
df['diagnosis'] = LabelEncoder().fit_transform(df['diagnosis'])
```

```
def standardize(X_tr, X_te):
    """Fit scaler su train, trasforma entrambi; restituisce DataFrame."""
    scaler = StandardScaler()
    def to_df(arr, ref): return pd.DataFrame(arr, columns=ref.columns, index=ref.index)
    return to_df(scaler.fit_transform(X_tr), X_tr), to_df(scaler.transform(X_te), X_te)
```


```
RangeIndex: 569 entries, 0 to 568
Data columns (total 32 columns):
```

#	Column	Non-Null Count	Dtype
0	id	569 non-null	int64
1	diagnosis	569 non-null	object
2	radius_mean	569 non-null	float64
3	texture_mean	569 non-null	float64

#	Column	Non-Null Count	Dtype
0	diagnosis	569 non-null	int64
1	radius_mean	569 non-null	float64
2	texture_mean	569 non-null	float64
3	perimeter_mean	569 non-null	float64
4	area_mean	569 non-null	float64
5	smoothness_mean	569 non-null	float64
6	compactness_mean	569 non-null	float64
7	concavity_mean	569 non-null	float64
8	concave points_mean	569 non-null	float64
9	symmetry_mean	569 non-null	float64
10	fractal_dimension_mean	569 non-null	float64
11	radius_se	569 non-null	float64
12	texture_se	569 non-null	float64
13	perimeter_se	569 non-null	float64
14	area_se	569 non-null	float64
15	smoothness_se	569 non-null	float64
16	compactness_se	569 non-null	float64
17	concavity_se	569 non-null	float64
18	concave points_se	569 non-null	float64
19	symmetry_se	569 non-null	float64
20	fractal_dimension_se	569 non-null	float64
21	radius_worst	569 non-null	float64
22	texture_worst	569 non-null	float64
23	perimeter_worst	569 non-null	float64
24	area_worst	569 non-null	float64
25	smoothness_worst	569 non-null	float64
26	compactness_worst	569 non-null	float64
27	concavity_worst	569 non-null	float64
28	concave points_worst	569 non-null	float64
29	symmetry_worst	569 non-null	float64
30	fractal dimension worst	569 non-null	float64



Importanza Feature



Le features sono state classificate per importanza tramite Random Forest; questa classificazione è usata più avanti

Tecniche di degradazione considerate

- Label Flipping
- Gaussian Noise
- Outlier Injection
- Missing Features
- Data Drift
- Random Feature Drop
- Top-K Drop
- Duplicates

E' stata fatta una scelta di quanto più a tutto tondo possibile, compatibilmente alle implementazioni fornite dalla libreria PuckTrick.


Pipelines

La pipeline sperimentale adottata introduce una struttura a tre livelli annidati rispetto alla baseline originale:




1. Il primo livello riguarda la modalità di selezione delle feature (all features, best 3, worst 3);
2. Il secondo livello copre il tipo di corruzione;
3. Il terzo livello definisce l'intensità di corruzione (19 livelli da 0.05 a 0.95 con step 0.05, più la baseline pulita a livello 0);
4. Ogni casistica iterata 20 volte per stabilità.

TOTALE: $3 \times 8 \times 20 \times 3 \times 20 = 28.800$ addestramenti.



Risultati “Worst 3” e “Best 3”





Risultati su variazioni numeriche




Risultati su missing features e duplicati



Risultati su rimozione di features



Risultati Label Flipping



Conclusioni

- Random Forest, consistentemente con la teoria, è costantemente più resistente a interferenze
- La Rete Neurale (MLP) è più prona a degradazione, per via della struttura elementare
- Label Flipping crea problemi indipendentemente dal modello
- Duplicates aiuta i modelli andando a migliorare leggermente
- Le Top Feature non sono essenziali se non per MLP

Fine